

# Aula 13 – Aritmética do Computador

## *Ponto Flutuante*

Prof. João Fernando Mari  
*joaofmari.github.io*

# Roteiro


- Números reais
- Exemplo.: Ponto fixo
- Ponto flutuante
- Expoente polarizado
- Normalização
- Exemplo: Ponto flutuante
- Números representáveis
- IEEE 754
- Aritmética de ponto flutuante (+/-)
- Exemplo: Soma e subtração
- Aritmética de ponto flutuante ( $\times/\div$ )

# Números reais


- Como representar os números reais no computador?
  - Poderia ser feito em binário puro.
    - $1001.1010 = 2^4 + 2^0 + 2^{-1} + 2^{-3} = 9.625$
- Onde está o ponto binário?
  - Fixo?
    - Muito limitado em termos de representação.
  - Móvel (ou flutuante)?
    - Onde está o ponto?

# EXEMPLP: Ponto fixo


- Suponha palavras de 8 bits:
  - 4 bits para a parte inteira e 4 bits para a parte real



- Aumentar o intervalo de inteiros, diminui a precisão da parte real




- Aumentar a precisão da parte real, diminui o intervalo de inteiros



# Ponto flutuante

- $\pm$  Significando  $\times 2^{\text{Exponente}}$



*Obs.: O termo Mantissa, encontrado em muitos livros texto, é considerado obsoleto. Usaremos Significando.*

# Expoente polarizado


- Expoente está em ***representação polarizada***.
  - Polarização: um valor fixo que é subtraído para obter o expoente.
    - Polarização:  $2^{k-1} - 1$  (k é o número de bits do expoente)
    - EXEMPLO: Expoente com 8 bits (Intervalo de 0 a 255)
      - A polarização é  $2^7 - 1 = 127$
      - Intervalo do expoente polarizado: -127 a +128.
        - »  $0 - 127 = -127$
        - »  $255 - 127 = 128$



# Normalização

- Números em ponto flutuante geralmente são normalizados, ou seja
  - O expoente é ajustado de modo que bit inicial (MSB) da significando seja 1.
  - Por ser sempre 1, não é preciso armazená-lo.
  - Ex.:  $00100101.001 \times 2^0 = 1.00101001 \times 2^5$ 
    - Armazenamos apenas 00101001
- Obs.: Em notação científica, os números são normalizados para um único dígito antes do ponto decimal:
  - Ex.:
    - $3123.0 = 3.123 \times 10^3$
    - $0.003123 = 3.123 \times 10^{-3}$

# Exemplos de ponto flutuante



(a) Formato


$$\begin{aligned} 1.1010001 \times 2^{10100} &= 0\ 10010011\ 101000100000000000000000 = 1.6328125 \times 2^{20} \\ -1.1010001 \times 2^{10100} &= 1\ 10010011\ 101000100000000000000000 = -1.6328125 \times 2^{20} \\ 1.1010001 \times 2^{-10100} &= 0\ 01101011\ 101000100000000000000000 = 1.6328125 \times 2^{-20} \\ -1.1010001 \times 2^{-10100} &= 1\ 01101011\ 101000100000000000000000 = -1.6328125 \times 2^{-20} \end{aligned}$$

(b) Exemplos




# Exemplos de ponto flutuante

- Valor em binário:
  - 0 | 10010011 | 101000100000000000000000
- Resolver o expoente polarizado:
  - $147 - 127 = 20_{10} = 10100_2$
- Incluir o bit 1 mais significativo do significando
  - + | 10100 | 1.101000100000000000000000
- Converte os valores para base decimal:
  - + | 20 | 1.6328125
- Colocar em notação científica:
  - (+/-)significando  $\times 2^{\text{expoente}}$
  - $+ 1.6328125 \times 2^{20} = 1.6328125 \times 1,048,576 =$
  - 1,712,128
- Valor em decimal:
  - + 1,712,128.0
- Valor em decimal:
  - + 1,712,128.0
- Converte para binário (a parte inteira e a parte decimal):
  - + 1 1010 0010 0000 0000 0000. 0
- Colocar em notação científica (base 2)
  - + 1 1010 0010 0000 0000 0000. 0  $\times 2^0$
- Mover o ponto até antes do bit 1 mais significativo:
  - + 1. 1010 0010 0000 0000 0000  $\times 2^{20}$
- Tornar o expoente polarizado e remover o 1 mais significativo:
  - $20 + 127 = 147$
  - + | 10010011 | 101000100000000000000000
- Valor em binário:
  - 0 | 10010011 | 101000100000000000000000




# Exemplos de ponto flutuante (significando negativo)

- Valor em binário:
  - **1** | 10010011 | 101000100000000000000000
- Resolver o expoente polarizado:
  - $147 - 127 = 20_{10} = 10100_2$
- Incluir o bit 1 mais significativo do significando
  - **-** | 10100 | 1.101000100000000000000000
- Converte os valores para base decimal:
  - **-** | 20 | 1.6328125
- Colocar em notação científica:
  - (+/-)significando  $\times 2^{\text{expoente}}$
  - $-1.6328125 \times 2^{20} = 1.6328125 \times 1,048,576 =$
  - **-1,712,128**
- Valor em decimal:
  - **-1,712,128.0**
- Valor em decimal:
  - **-1,712,128.0**
- Converte para binário (a parte inteira e a parte decimal):
  - **-1** 1010 0010 0000 0000 0000. 0
- Colocar em notação científica (base 2)
  - **-1** 1010 0010 0000 0000 0000. 0  $\times 2^0$
- Mover o ponto até antes do bit 1 mais significativo:
  - **-1.** 1010 0010 0000 0000 0000  $\times 2^{20}$
- Tornar o expoente polarizado e remover o 1 mais significativo:
  - $20 + 127 = 147$
  - **-** | 10010011 | 101000100000000000000000
- Valor em binário:
  - **1** | 10010011 | 101000100000000000000000




# Exemplos de ponto flutuante (expoente negativo)

- Valor em binário:
  - 0 | 01101011 | 101000100000000000000000
- Resolver o expoente polarizado:
  - $107 - 127 = -20$
- Incluir o bit 1 mais significativo do significando
  - + | -10100 | 1.101000100000000000000000
- Converte os valores para base decimal:
  - + | -20 | 1.6328125
- Colocar em notação científica:
  - (+/-)significando  $\times 2^{\text{expoente}}$
  - $+ 1.6328125 \times 2^{-20} =$
- Valor em decimal (um número muito pequeno):
  - + 0.000001557171344757080078125




# Exemplos de ponto flutuante (com valores reais)

- Valor em decimal:
  - + 20.3
- Converte para binário (a parte inteira e a parte decimal):
  - + 1 0100 . 0100 1100 1100 1100 1100 1100 (...)
- Colocar em notação científica (base 2)
  - + 1 0100 . 0100 1100 1100 1100 1100 1100 x 2<sup>0</sup>
- Mover o ponto até antes do bit 1 mais significativo:
  - + 1 . 0100 0100 1100 1100 1100 1100 1100 x 2<sup>4</sup>
- Tornar o expoente polarizado e remover o 1 mais significativo do significando (manter apenas 23 bits):
  - 4 + 127 = 131<sub>10</sub> = 1000 0011<sub>2</sub>
  - + | 1000 0011 | 0100 0100 1100 1100 1100 110
- Valor em binário:
  - 0 | 1000 0011 | 0100 0100 1100 1100 1100 110
- Valor em binário:
  - 0 | 1000 0011 | 0100 0100 1100 1100 1100 110
- Resolver o expoente polarizado:
  - 131 - 127 = 4<sub>10</sub> = 100<sub>2</sub>
- Incluir o bit 1 mais significativo do significando
  - + | 100 | 1. 0100 0100 1100 1100 1100 110
- Converte os valores para base decimal:
  - + | 4 | 1.268749952316284
- Colocar em notação científica:
  - (+/-)significando x 2<sup>expoente</sup>
  - + 1.268749952316284 x 2<sup>4</sup>
  - + 1.268749952316284 x 16 =
  - + 20.299999924
- Valor em decimal (arredondando):
  - + 20.3



# Números representáveis

- Intervalos de números expressos em 32 bits



# IEEE 754

- Padrão para armazenamento de ponto flutuante.
- Padrões de 32 e 64 bits.
- Expoente de 8 e 11 bits, respectivamente.



(a) Formato isolado




(b) Formato duplo

# Aritmética de ponto flutuante (+/-)

- Algoritmo para soma e subtração de números binários em ponto-flutuante:
  - Verifique zero
  - Alinhe significandos (ajustando expoentes)
  - Some ou subtraia significandos
  - Verifique *overflow* ou *underflow*
  - Normalize o resultado
  - Arredonde o resultado


# Fluxograma da adição e subtração de ponto flutuante

- $Z = X + Y$
- $Z = X - Y$ 
  - $Z = X + (-Y)$





# Exemplo




|                                         |                        |
|-----------------------------------------|------------------------|
| 20.3                                    | 5.25                   |
| $10100.01001100110011 (...) \times 2^0$ | $101.01 \times 2^0$    |
| $1.01000100110011 \times 2^4$           | $1.0101 \times 2^2$    |
| $4 + 15 = 19$                           | $2 + 15 = 17$          |
| 0   10011   0100010011                  | 0   10001   0101000000 |


Polarização: Se  $k=5$ , então  $2^4 - 1 = 15$

Limites do expoente normalizado:

$0 - 15 = -15$  até  $2^5 - 1 - 15 = 31 - 15 = 16$



# Exemplo



20.3 + 5.25

20.3

0 | 10011 | 1.0100010011

(19)

1.0100010011

0.0101010000 +

1.1001100011

Resultado:

0 | 10011 | 1001100011

Polarização: 19 – 15 = 4

Convertendo para verificar:

$1.5966796875 \times 2^4 =$

$25.546875 = 25.55$  (arredondando)

5.25

0 | 10001 | 1.0101000000

(17) + 1 = 18

0 | 10010 | 0.1010100000 | 0


(18) + 1 = 19

0 | 10011 | 0.0101010000 | 0

(19)

$1.0100010011 \times 2^4$  (normalizado)



$10100.010011 \times 2^0$  (desnormalizado)





# Aritmética de ponto flutuante ( $\times/\div$ )

- Verifique zero.
- Some/subtraia expoentes.
- Multiplique/divida significandos (observe o sinal).
- Normalize.
- Arredonde.
- Resultados intermediários armazenados em tamanho duplo.

# Multiplicação e divisão de ponto flutuante




# Multiplicação e divisão de ponto flutuante



# Referências

- STALLINGS, W. **Arquitetura e Organização de Computadores**, 8. Ed., Pearson, 2010.
  - **Capítulo 9**



**FIM DA DISCIPLINA!**