Aula 03 – Avaliando o desempenho

Prof. João Fernando Mari
joaofmari.github.io

Roteiro

- Definindo o desempenho
- Exemplo: Vazão e tempo de resposta
- Tempo de resposta
- Exemplo: Desempenho relativo
- Medindo o desempenho
- Desempenho da CPU e seus fatores
- Exemplo: Melhorando o desempenho
- Interface Hardware/Software
- Exemplo: Usando a equação do desempenho
- Entendendo o desempenho dos programas
- Exemplo: Comparando segmentos de código
- Avaliando o desempenho
- Tempo de execução total
- Lei de Amdahl
- MIPS – Milhões de instruções por segundo

DEFININDO O DESEMPENHO

Definindo o desempenho

- Executando o mesmo programa em dois desktops diferentes:
  - O mais rápido é o que ***termina uma tarefa primeiro***.

- CPD (central de processamento de dados) com vários servidores realizando tarefas submetidas por muitos usuários:
  - O mais rápido é aquele que completou ***a maior quantidade de tarefas*** durante um determinado período.

Definindo o desempenho

- Computador individual:
  - Reduzir o tempo de resposta;
  - Tempo de resposta (tempo de execução ou **latência**) :
    - O tempo entre o inicio e o término de uma tarefa.

- CPDs:
  - Aumentar a vazão;
  - Vazão (***throughput***):
    - Quantidade de trabalho feito em determinado tempo.

Exemplo: Vazão e tempo de resposta

- As seguintes mudanças e um sistema computacional aumentam a vazão, diminuem o tempo de resposta ou as duas coisas?
  - 1) Substituir o processador em com computador por uma versão mais rápida.
  - 2) Incluir processadores adicionais em um sistema que usa múltiplos processadores para tarefas distintas – por exemplo, busca na Web.

- **RESPOSTA:**
- Diminuir o tempo de resposta quase sempre aumenta a vazão.
  - Caso 1) Tanto o tempo de resposta como a vazão são melhorados
  - Caso 2) Como nenhuma tarefa é realizada primeiro, apenas a vazão é melhorada
    - Demanda por processamento maior que a vazão → **enfileiramento**.
      - Aumentar a vazão implicaria na redução do tempo de resposta pois reduziria o tempo de espera na fila.

Tempo de resposta

- **Tempo de resposta**:
  - Nossa principal preocupação!
- Para maximizar o desempenho devemos minimizar o tempo de execução de uma determinada tarefa:
  - $Desempenho_X = 1 / TempoDeExecução_X$

- Para dois computadores X e Y, se o desempenho de X é maior que o de Y, temos:
  - $Desempenho_X > Desempenho_Y$
  - $1 / TempoDeExecução_X > 1 / TempoDeExecução_Y$
  - $TempoDeExecução_X < TempoDeExecução_Y$
- X é mais rápido de que Y, se o tempo de execução em Y é maior do que em X.

Desempenho relativo

- Relacionar o desempenho de dois computadores diferentes de maneira quantitativa
  - X é n vezes mais rápido do que Y:
  - $n = Desempenho_X / Desempenho_Y$

- Se X é n vezes mais rápido que Y, então...
  - O tempo de execução em Y é n vezes maior do que em X:
  - $n = TempoDeExecução_Y / TempoDeExecução_X$

Exemplo: Desempenho relativo

- Um computador A executa um programa em 10 segundos e o computador B executa o mesmo programa em 15 segundos. O quanto A é mais rápido do que B?
  - Sabemos que A é n vezes mais rápido que B se
    - $\text{Desempenho}_A / \text{Desempenho}_B = n$
    - $\text{TempoDeExecução}_B / \text{TempoDeExecução}_A = n$
    - Fator de desempenho é:
      - 15 / 10 = 1,5
  - A é 1,5 vezes mais rápido que B
    - Ou B é 1,5 vezes mais lento do que A
    - $\text{Desempenho}_A / \text{Desempenho}_B = 1,5$
    - $\text{Desempenho}_A / 1,5 = \text{Desempenho}_B$

MEDINDO O DESEMPENHO

Medindo o desempenho

- O tempo é a medida do desempenho dos computadores
  - O computador que realiza a mesma quantidade de trabalho em menos tempo é mais rápido.

- Tempo de execução do programa:
  - Medido em segundos por programa
  - Pode ser definido de diferentes maneiras:

- **Tempo de relógio (tempo de resposta ou tempo decorrido):**
  - Tempo total para executar uma tarefa
    - Incluindo acesso a disco, acesso a memória, atividades de E/S etc...

Medindo o desempenho

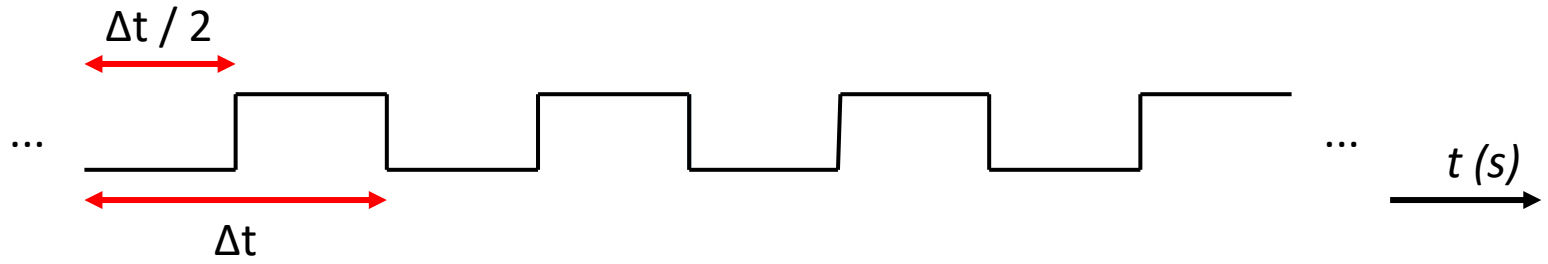
- Processadores trabalham em diversos programas simultaneamente...
  - Otimizar a vazão em vez de minimizar o tempo para cada programa.

- É necessário distinguir entre tempo decorrido e tempo que o processador trabalha para nós:
- **Tempo de execução de CPU (tempo de CPU):**
  - Tempo real que a CPU gasta computando uma tarefa especifica
  - Não inclui o tempo gasto esperando E/S ou executando outros programas
  - ***Tempo de CPU do usuário:***
    - Tempo que a CPU gasta efetivamente com o programa
  - ***Tempo de CPU do sistema:***
    - Tempo da CPU gasta no SO realizando tarefas a pedido do programa

- Desempenho do sistema → Tempo decorrido
- Desempenho da CPU → Tempo de CPU

Medindo o desempenho

- Medir a rapidez com que o hardware realiza funções básicas
- **Clock:**
  - Relógio que trabalha em velocidade constante e determina quando os eventos ocorrem
  - Período de clock, ciclo de clock
    - Tempo de cada ciclo de clock (Ex: 0,25 ns, 250 ps)
    - Velocidade de clock (Ex: 4GHz)
      - Inverso do período de clock, frequência do processador.
      - Medido em Hz (*hertz* – ciclos por segundo).



Desempenho da CPU e seus fatores

- Desempenho da CPU:
  - Medida de desempenho final → Tempo de execução da CPU
  - Medidas mais básicas (ciclos de clock e tempo de ciclo de clock)

$$\text{Tempo de execução da CPU para um programa} = \text{Ciclos de clock da CPU para um programa} \times \text{Tempo de ciclo de clock}$$

  - Como velocidade do clock e tempo do ciclo de clock são inversos:

$$\text{Tempo de execução da CPU para um programa} = \frac{\text{Ciclos de clock da CPU para um programa}}{\text{Velocidade de clock}}$$

  - Melhorar o desempenho → reduzir a duração do ciclo de clock ou o número de ciclos necessários para um programa
  - Muitas técnicas que diminuem o número de ciclos de clock aumentam o tempo do ciclo.

Exemplo: Melhorando o desempenho

- Um computador A possui clock de 4GHz e executa um determinado programa em 10 segundos.
- Queremos construir um computador B que execute esse mesmo programa em 6 segundos.
  - Entretanto, aumentar a velocidade do clock afeta o projeto da CPU e faz com que o computador B exija 1,2 vezes mais ciclos de clock do que A.
- Que velocidade de clock o projetista deve buscar?

Exemplo: Usando a equação do desempenho

- Número de ciclos de clock necessários para o programa em A:
  - Tempo de CPU_A = Ciclos de clock da CPU_A / Velocidade de $clock_A$
  - 10 segundos = Ciclos de clock da CPU_A / (4 x 10^9 ciclos/seg.) (4GHz).
  - Ciclos de clock da CPU_A = 10 seg. × (4 × 10^9 ciclos/seg.)
  - Ciclos de clock da CPU_A = 40 x 10^9 ciclos

- O tempo de CPU para B
  - Tempo de CPU_B = 1,2 × ciclos de clock de CPU_A / velocidade de $clock_B$
  - 6 segundos = 1,2 x 40 x 10^9 ciclos / Velocidade de $clock_B$
  - Velocidade de $clock_B$ = 1,2 x 40 x 10^9 ciclos / 6 seg =
  - = 8 x 10^9 ciclos / seg = 8GHz
- A velocidade de clock de B deve ser o dobro da velocidade de clock de A

Interface Hardware/Software

- Equações anteriores não consideram o número de instruções necessárias para o programa

$$TempoDeExecução = númeroDeInstruçõesExecutadas \times tempoMédioDeCadaInstrução$$

- Número de ciclos de clock necessários para um programa:

Ciclos de clock da CPU	=	Instruções para um programa	×	Média dos ciclos de clock por instrução

- Ciclos de clock por instrução (CPI) → Número médio de ciclos de clock que cada instrução leva para ser executada
  - Diferentes instruções → diferentes quantidades de tempo
  - CPI = média de todas as instruções executadas no programa
  - Comparar duas implementações diferentes do mesmo conjunto de instruções

Exemplo: Usando a equação do desempenho

- Duas implementações do mesmo conjunto de instruções.
  - O computador A tem um tempo de ciclo de clock de 250 ps e um CPI de 2,0 para um determinado programa.
  - O computador B tem um ciclo de clock de 500 ps e um CPI de 1,2 para o mesmo programa.
- Qual computador é mais rápido para esse programa e o quanto é mais rápido?

Exemplo: Usando a equação do desempenho

- Cada computador executa o mesmo número de instruções (I).
- Encontrar o número de ciclos de *clock* do processador para cada computador.
  - Ciclos de *clock* da CPU_A = I x 2,0
  - Ciclos de *clock* da CPU_B = I x 1,2
- Tempo da CPU para cada computador
  - Tempo da CPU_A = Ciclos de *clock* da CPU_A x Tempo dos ciclos de $clock_A$
    = I x 2,0 x 250 ps = 500 x I ps
  - Tempo da CPU_B = I x 1,2 x 500 ps = 600 x I ps
- Computador A é mais rápido que B. Quanto?

$$\frac{DesempenhoDaCPU_A}{DesempenhoDaCPU_B} = \frac{TempoDeExecução_B}{TempoDeExecução_A} = \frac{600 \times I\ ps}{500 \times I\ ps} = 1{,}2$$

- Computador A é 1,2 vezes mais rápido que o computador B.

Exemplo: Usando a equação do desempenho

- Equação do desempenho em termos de:
  - Contagem de instruções,
  - CPI e
  - Tempo de ciclo de *clock*.

$$TempoDeCPU = ContagemDeInstruções \times CPI \times TempoDeCicloDeClock$$

  - ou

$$TempoDeCPU = \frac{ContagemDeInstruções \times CPI}{Velocidade\ de\ clock}$$

- Comparar duas implementações diferentes ou avaliar um projeto alternativo.

Exemplo: Usando a equação do desempenho

- Equação do desempenho em termos de:
  - Contagem de instruções,
  - CPI e
  - Tempo de ciclo de *clock*.

$$TempoDeCPU = \underbrace{ContagemDeInstruções \times CPI}_{\text{Ciclos de clock da CPU}} \times TempoDeCicloDeClock$$

  - ou

$$TempoDeCPU = \frac{ContagemDeInstruções \times CPI}{Velocidade\ de\ clock}$$

- Comparar duas implementações diferentes ou avaliar um projeto alternativo.

Desempenho da CPU e seus fatores

- Ciclos de clock da CPU:

$$CiclosDeClockDaCPU = \sum_{i=1}^{n} (CPI_i \times C_i)$$

  - C_i: contagem do número de instruções da classe i executadas
  - CPI_i: a média dos ciclos por instrução da classe i
  - n é o número de classes de instrução.
- CPI geral de um programa dependerá do número de ciclos para cada tipo de instrução e da frequência de cada tipo de instrução.

Desempenho da CPU e seus fatores

- Como determinar o valor desses fatores na equação do desempenho?
  - **Tempo da CPU** – executando o programa.
  - **Tempo de ciclo de *clock*** – publicado com o equipamento.
  - **Contagem de instruções (C) e o CPI** – mais difíceis de obter.
- Contagem de instruções (C):
  - Ferramentas de software ou simuladores da arquitetura
- CPI – Varia de acordo com o programa e implementação do conjunto de instruções
  - Pode ser obtida por simulação da implementação ou contadores de hardware

Tempo de execução

- Como os fatores são combinados para fornecer o tempo de execução por segundo

$$Tempo = \frac{Segundos}{Programa} = \frac{Instruções}{Programa} \times \frac{Ciclos\ de\ clock}{Instrução} \times \frac{Segundos}{CiclosDeClock}$$

Componentes do desempenho	Unidade de medida
Tempo de execução da CPU para um programa	Segundos por programa
Contagem de instruções	Instruções executadas para o programa
Ciclos de clock por instrução	Média de ciclos de clock por instrução
Tempo de ciclo de clock	Segundos por ciclo de clock

- Única medida completa e confiável de desempenho do computador é o tempo.
  - Exemplo: Mudar o conjunto de instruções para baixar a contagem de instruções pode aumentar o tempo do ciclo de clock
    - CPI depende da instrução. O menor número de instruções executadas pode não ser mais rápido.

Resumo

Tempo de relógio:

- $\text{Desempenho}_X = 1 / \text{TempoDeExecução}_X$
- $n = \text{Desempenho}_X / \text{Desempenho}_Y$

Tempo de CPU:

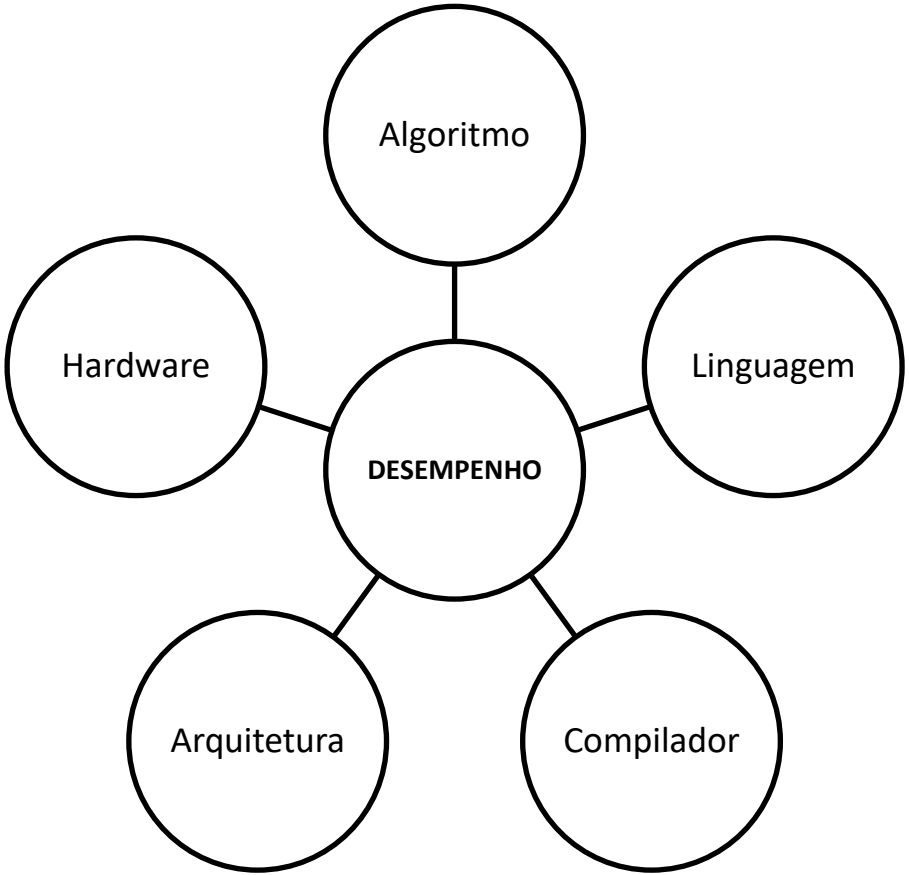
Tempo de execução da CPU para um programa (Tempo de CPU)	=	Ciclos de clock da CPU para um programa	×	Tempo de ciclo de clock

Ciclos de clock da CPU para um programa	=	Instruções para um programa (Contagem de instruções)	×	Média dos ciclos de clock por instrução (CPI)

$$TempoDeCPU = \underbrace{ContagemDeInstruções \times CPI}_{\text{Ciclos de clock da CPU}} \times TempoDeCicloDeClock$$

ENTENDENDO O DESEMPENHO DOS PROGRAMAS

Entendendo o desempenho dos programas



Entendendo o desempenho dos programas

- Algoritmo
  - Afeta a contagem de instruções e possivelmente o CPI.
    - *O algoritmo determina o número de instruções do programa fonte executadas e, portanto, o número de instruções do processador executadas.*
    - *Pode afetar o CPI, favorecendo instruções mais lentas ou mais rápidas. Por exemplo, se o algoritmo usar mais operações de ponto flutuante, ele terá um CPI mais alto*.
- Linguagem de programação
  - Contagem de instruções, CPI.
    - *As instruções da linguagem são traduzidas em instruções do processador, que determinam a contagem de instruções.*
    - *Pode afetar o CPI devido aos seus recursos; por exemplo, uma linguagem com pesado suporte a abstrações de dados (como Java) exigira chamadas indiretas, que usarão instruções de CPI mais altos.*

Entendendo o desempenho dos programas

- Compilador
  - Contagem de instruções, CPI.
    - *O compilador determina a tradução das instruções da linguagem fonte para instruções do computador.*
- Conjunto de instruções
  - Contagem de instruções, velocidade de clock, CPI
    - *Afeta os três aspectos do desempenho da CPU, uma vez que ele afeta as instruções necessárias para uma função, o custo em ciclos de cada instrução e a velocidade geral do processador.*

Exemplo: Comparando segmentos de código

- O projetista de um compilador precisa decidir entre duas sequencias de código para um determinado computador:

	CPI para cada classe de instruções		
	A	B	C
CPI	1	2	3

- Para uma determinada instrução da linguagem de alto nível, o projetista do compilador está considerando duas sequencias de código que exigem as seguintes contagens de instrução:

	Contagens de instrução para classe de instrução		
Sequencia de código	A	B	C
1	2	1	2
2	4	1	1

- Qual sequencia de código executa mais instruções? Qual será a mais rápida? Qual é o CPI para cada sequencia?

Exemplo: Comparando segmentos de código

RESPOSTA:

- A sequencia 1 executa 2 + 1 + 2 = 5 instruções
- A sequencia 2 executa 4 + 1 + 1 = 6 instruções
  - Logo, a sequencia 2 executa mais instruções

- Equação para os ciclos de clock de CPU
  - Contagem de instruções e CPI

$$CiclosDeClockDeCPU = \sum_{i=1}^{n} (CPI_i \times C_i)$$

- Isso resulta em:
  - Ciclos de clock da CPU_1 = (1 x 2) + (2 x 1) + (3 x 2) = 2 + 2 + 6 = 10 ciclos
  - Ciclos de clock de CPU_2 = (1 x 4) + (2 x 1) + (3 x 1) = 4 + 2 + 3 = 9 ciclos

Exemplo: Comparando segmentos de código

RESPOSTA:

- A sequencia de código 2 é a mais rápida, mesmo executando uma instrução extra
  - Os valores de CPI podem ser calculador por:

$$CPI = \frac{CiclosDeClockDaCPU}{ContagemDeInstruções}$$

$$CPI_1 = \frac{CiclosDeClockDaCPU_1}{ContagemDeInstruções_1} = \frac{10}{5} = 2$$

$$CPI_2 = \frac{CiclosDeClockDaCPU_2}{ContagemDeInstruções_2} = \frac{9}{6} = 1{,}5$$

AVALIANDO O DESEMPENHO

Avaliando o desempenho

- ***Workload:***
  - Um conjunto de programas executados em um computador
- ***Benchmark:***
  - Programas especificamente escolhidos para medir desempenho
  - Formam um *workload* (carga de trabalho)
  - O melhor tipo de programa para *benchmark* são as aplicações reais
  - Diferentes classes e aplicações exigem diferentes tipos de benchmarks
    - **Desktop** → desempenho de CPU ou alguma tarefa especifica
    - **Servidores Científicos** → orientados a CPU (tempo de resposta)
    - **Servidores** → serviços Web, compartilhamento de arquivos, banco de dados (vazão)
    - **Computação embarcada** → poucos benchmarks, próprias aplicações
    - **Smartphones** → ...
  - Reprodutibilidade.

Avaliando o desempenho

- Selecionados os programas a serem usados como benchmarks
  - Decidido entre medir tempo de execução e vazão
- Como resumir o desempenho de um grupo de benchmarks

Workload	Computador A	Computador B
Programa 1 (seg.)	1	10
Programa 2 (seg.)	1000	100
Tempo total (seg.)	1001	110

- A é 10 vezes mais rápido que B para o prog. 1
- B é 10 vezes mais rápido que A para o prog. 2
- O desempenho relativo dos computadores A e B não é claro

Tempo de execução total

- Resumir desempenho relativo
  - Usar o tempo de execução total dos dois programas

$$\frac{Desempenho_B}{Desempenho_A} = \frac{TempoDeExecução_A}{TempoDeExecução_B} = \frac{1001}{110} = 9{,}1$$

  - B é 9,1 vezes mais rápido do que A para os programas 1 e 2 juntos

- Média aritmética (MA):
  - Diretamente proporcional ao tempo de execução total

$$MA = \frac{1}{n}\sum_{i=1}^{n} Tempo_i$$

- Média Aritmética Ponderada:
  - Utiliza pesos destinados a refletir a presença dos programas em um *workload*

Lei de Amdahl

- O aumento de desempenho possível com uma determinada melhoria é limitado pela quantidade de uso do recurso melhorado

$$TempoDeExecuçãoAposMelhoria = \frac{TempoDeExecuçãoAfetadoPelaMelhoria}{QualidadeDaMelhoria} + TempoDeExecuçãoNãoAfetado$$

- Consequência da lei de Amdahl: torne o caso comum rápido
  - A frequência de alguns eventos é muito maior do que outros.
  - Geralmente o caso comum é mais simples.

MIPS – Milhões de instruções por segundo

- Alternativa para o tempo com métrica de desempenho
  - Baseado no número de milhões de instruções

$$MIPS = \frac{ContadorDeInstruções}{TempoDeExecução \times 10^6}$$

- Computadores mais rápidos possuem um índice MIPS mais alto
  - Mais fácil de ser entendido
- **Problemas:**
  - Considera a taxa de execuções de instruções
    - Desconsidera a capacidade das instruções
    - Não permite comparar computadores com diferentes conjuntos de instruções
  - O MIPS vária entre programas no mesmo computador
  - Pode variar inversamente com o desempenho!

Não confundir com arquitetura MIPS (Microprocessor without Interlocked Pipeline Stages)

Exemplo: MIPS como medida de desempenho

- Computador com três classes de instruções e medições de CPI

	CPI para está classe de instrução		
	A	B	C
CPI	1	2	3

- Medindo o código gerado por dois compiladores diferentes para o mesmo programa

	Contagens de instrução para classe de instrução		
Sequencia de código	A	B	C
1	5×10^9	1×10^9	1×10^9
2	10×10^9	1×10^9	1×10^9

- Velocidade de clock de 4GHz.
- Qual sequencia de código será executada mais rápido de acordo com o MIPS? E de acordo com o tempo de execução?

Exemplo: MIPS como medida de desempenho

- Encontramos o tempo de execução:

$$TempoDeExecução = \frac{CiclosDeClockdaCPU}{VelocidadeDeClock}$$

- Para os ciclos de clock da CPU:

$$CiclosDeClockDaCPU = \sum_{i=1}^{n} (CPI_i \times C_i)$$

$$CiclosDeClockDaCPU_1 = (1 \times 5 + 2 \times 1 + 3 \times 1) \times 10^9 = 10 \times 10^9$$
$$CiclosDeClockDaCPU_2 = (1 \times 10 + 2 \times 1 + 3 \times 1) \times 10^9 = 15 \times 10^9$$

- Tempo de execução para os dois compiladores:

$$TempoDeExecução_{\ 1} = \frac{10 \times 10^9}{4 \times 10^9} = 2{,}5\ seg. \qquad TempoDeExecução_{\ 2} = \frac{15 \times 10^9}{4 \times 10^9} = 3{,}75\ seg.$$

- De acordo com o **tempo de execução** o compilador 1 gera o programa mais rápido

Exemplo: MIPS como medida de desempenho

- O índice MIPS para cada versão do programa

$$MIPS = \frac{ContagemDeInstruções}{TempoDeExecução \times 10^6}$$

$$MIPS_1 = \frac{(5 + 1 + 1) \times 10^9}{2{,}5 \times 10^6} = 2.800$$

$$MIPS_2 = \frac{(10 + 1 + 1) \times 10^9}{3{,}75 \times 10^6} = 3.200$$

- Código do compilador 2 possui índice MIPS mais alto
- Código do compilador 1 é executado mais rápido
  - MIPS pode falhar em fornecer o desempenho

Apêndice – Frações de segundo

Unidade	Em segundos
Segundo (s)	1 s
Milisegundos (ms)	0,001 s (1×10^{-3} s)
Microsegundos (µs)	0,000001 s (1×10^{-6} s)
Nanosegundos (ns)	0,000000001 s (1×10^{-9} s)
Picosegundos (ps)	0,000000000001 s (1×10^{-12} s)

Bibliografia

- PATTERSON, D. A.; HENNESSY, J. L. **Organização e Arquitetura de computadores: a interface hardware/software**. 3. ed. Rio de Janeiro: Elsevier, 2005.
  - CAPÍTULO 2

FIM